Detecção de Padrões Atípicos em Eleições Municipais Brasileiras Utilizando Processamento Paralelo

Relatório de Progresso do Projeto — Ano 2026

PPCA – Programa de Pós-Graduação em Computação Aplicada | UnB

Índice de Conteúdo

1. Contextualização do Problema
2. Objetivo Geral e Específicos
3. Descrição dos Dados
4. Etapa 1 — Coleta e Ingestão dos Microdados (TSE)
5. Etapa 2 — Pré-processamento e Construção do Dataset Mestre
6. Etapa 3 — Análise Exploratória (EDA)
7. Próximas Etapas

1. Contextualização do Problema

As eleições municipais brasileiras constituem um dos processos democráticos de maior abrangência territorial e volumetria de dados no país. Realizadas a cada quatro anos, abrangem mais de 5.500 municípios e envolvem milhões de candidatos, eleitores e registros acumulados ao longo de décadas. Esses dados, disponibilizados publicamente pelo Tribunal Superior Eleitoral (TSE), representam um repositório de elevado valor analítico para a compreensão do comportamento político-eleitoral brasileiro.

A identificação de padrões atípicos — comportamentos estatisticamente discrepantes em relação ao conjunto observado — constitui uma linha de pesquisa relevante tanto científica quanto praticamente. Anomalias em resultados eleitorais, concentrações incomuns de votos, variações abruptas no desempenho de candidatos ou inconsistências nos perfis sociopolíticos dos eleitos são exemplos de fenômenos que merecem investigação sistemática.

O desafio técnico central reside no volume e na heterogeneidade dos dados. O conjunto de informações eleitorais do TSE, acumulado entre 2004 e 2024, compreende dezenas de milhões de registros distribuídos em múltiplas tabelas, justificando a adoção de técnicas de Big Data e computação paralela.

2. Objetivo Geral e Específicos

Objetivo Geral

Detectar padrões atípicos nas eleições municipais brasileiras (2004–2024) por meio de mineração de dados em larga escala e processamento paralelo, visando identificar comportamentos eleitorais discrepantes que possam subsidiar análises de integridade eleitoral.

Objetivos Específicos

- Consolidar e estruturar a base de dados eleitorais do TSE (2004–2024).
- En

3. Descrição dos Dados

Fontes Utilizadas

Fonte	Dataset	Período	Formato	Volume estimado
TSE	Candidatos	2004–2024	CSV/ZIP	~3M registros
TSE	Votação por mun./zona	2004–2024	CSV/ZIP	~4M registros
TSE	Bens declarados	2004–2024	CSV/ZIP	~5M registros
IBGE	População/IDHM	2000–2022	CSV/XLSX	~60k registros

Os dados do TSE estão organizados por ano eleitoral e unidade federativa, em formato CSV com encoding latin-1 e separador ponto-e-vírgula. Foram selecionadas as variáveis de maior relevância para o projeto: identificação do candidato, partido, cargo, município, resultado eleitoral, gênero,

escolaridade, estado civil, ocupação e patrimônio declarado.

4. Etapa 1 — Coleta e Ingestão dos Microdados

Módulos implementados

- config.py — URLs reais do CDN do TSE, anos municipais, cargos, encoding, colunas de interesse.

Resultados da validação — Ano 2024

Dataset	Arquivo ZIP	Linhas brutas	Após filtro	Parquet
candidatos	63,5 MB	463.802	447.792	18,7 MB
votacao_munzona	48,1 MB	717.310	717.310	22,0 MB
bens_candidatos	45,6 MB	910.861	910.861	24,6 MB

Problemas identificados e corrigidos

- Encoding: arquivos de todos os anos usam latin-1 (não utf-8 como inicialmente suposto).

5. Etapa 2 — Pré-processamento e Dataset Mestre

Transformações aplicadas

- Candidatos: substituição de valores mascarados do TSE (“NÃO DIVULGÁVEL”, “#NE”, “#NULO”) por NaN; criação de RESULTADO_SIMPLIFICADO, ELEITO (binário), GRAU_INSTRUCAO_ORD (ordinal 0–8) e GENERO (M/F/Outro).

Estatísticas do dataset mestre — 2024

Métrica	Valor
Total de candidatos	447.792
Prefeitos	15.761
Vereadores	432.031
Candidatos eleitos	63.713 (14,2%)
Com votos registrados	427.099 (95,4%)
Com patrimônio declarado	283.009 (63,2%)
Patrimônio máximo	R$ 12,1 bilhões
Votos máximos	5.194.249
Mediana de votos	88

6. Etapa 3 — Análise Exploratória (EDA)

6.1 Distribuição de votos por cargo

A distribuição de votos é fortemente assimétrica (cauda longa) em ambos os cargos. Para vereadores, a mediana é de apenas 88 votos, enquanto o máximo chega a 161.386. Para prefeitos, a mediana é de 2.558 votos e o máximo de 5,19 milhões. Essa assimetria é um indicativo natural de outliers que merecem atenção na fase de detecção de anomalias.

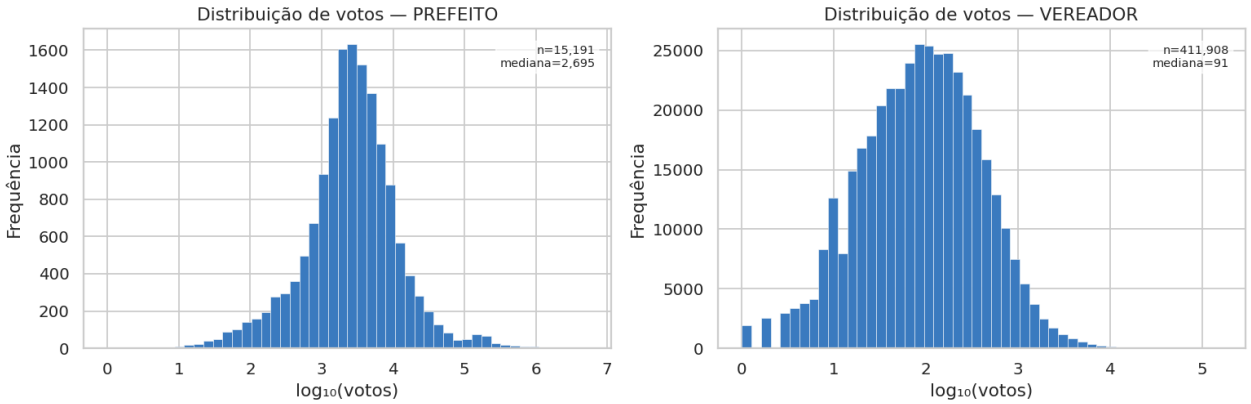

Fig. 1 — Distribuição de votos em escala logarítmica por cargo (2024)

6.2 Taxa de eleição por gênero

Candidatos masculinos apresentam taxa de eleição consistentemente superior: 36,1% vs 30,5% para prefeito e 17,0% vs 6,9% para vereador. A diferença entre gêneros é especialmente acentuada entre vereadores, sugerindo barreiras estruturais à eleição feminina.

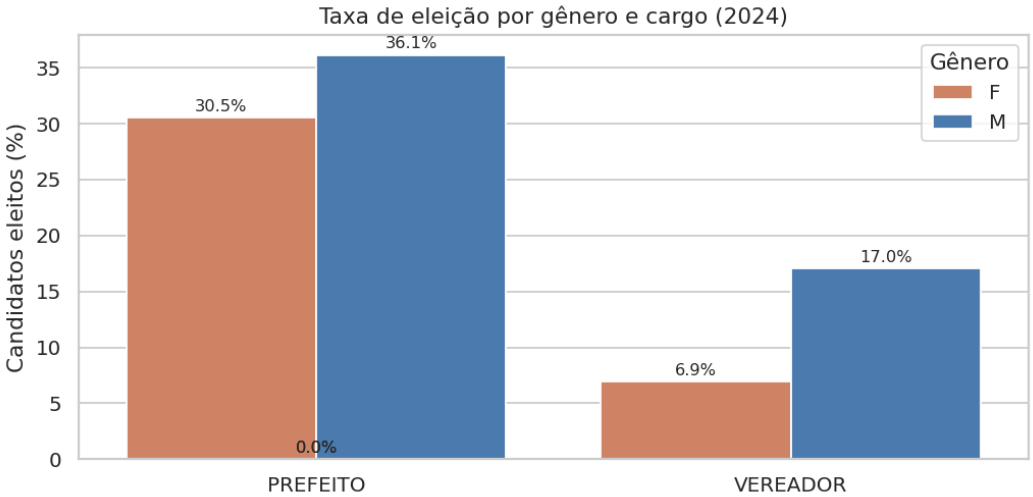

Fig. 2 — Taxa de eleição por gênero e cargo (2024)

6.3 Partidos com maior número de eleitos

MDB, PP e PSD lideram em número de vereadores eleitos, refletindo a capilaridade dessas siglas no interior do país. Entre os prefeitos, MDB e PP também dominam, consolidando o perfil das grandes máquinas partidárias municipais brasileiras.

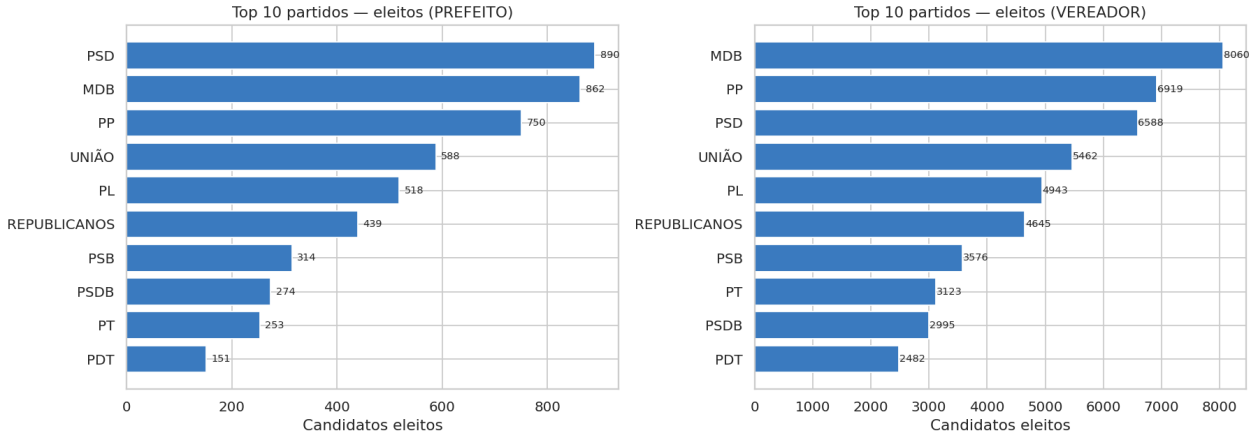

Fig. 3 — Top 10 partidos por candidatos eleitos, por cargo (2024)

6.4 Patrimônio declarado: eleitos vs não eleitos

Candidatos eleitos apresentam patrimônio mediano superior ao dos não eleitos em ambos os cargos, embora a diferença não seja determinante isoladamente. Nota-se também a existência de candidatos não eleitos com patrimônio declarado muito elevado, o que configura um padrão atípico a ser investigado.

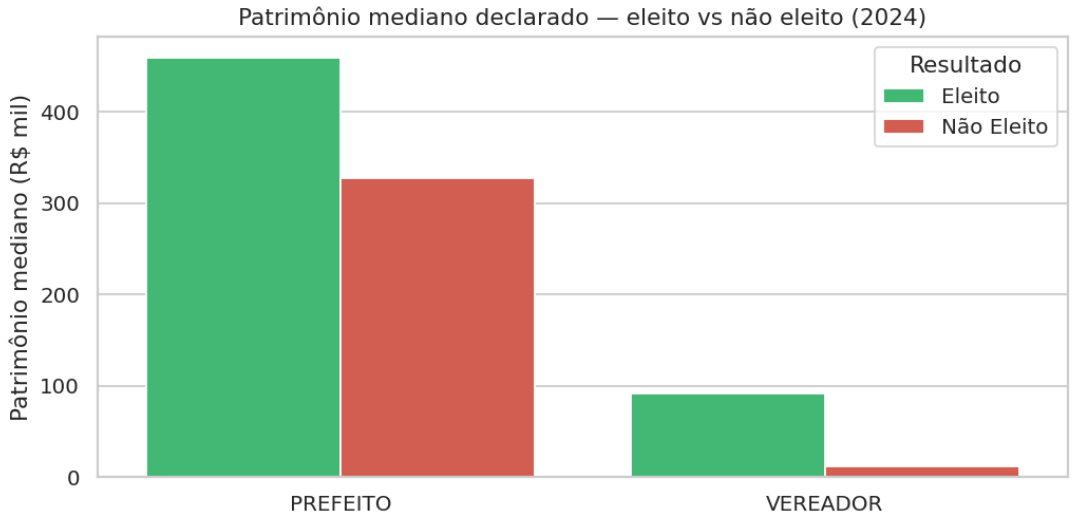

Fig. 4 — Patrimônio mediano declarado por resultado e cargo (2024, R$ mil)

6.5 Taxa de eleição de vereadores por UF e gênero

O mapa de calor revela heterogeneidade regional significativa. Estados como RR e RO apresentam taxas de eleição masculina acima de 20%, enquanto estados maiores (SP, MG) têm taxas menores devido ao maior número de candidatos por vaga. A desigualdade de gênero é sistemática em todas as UFs.

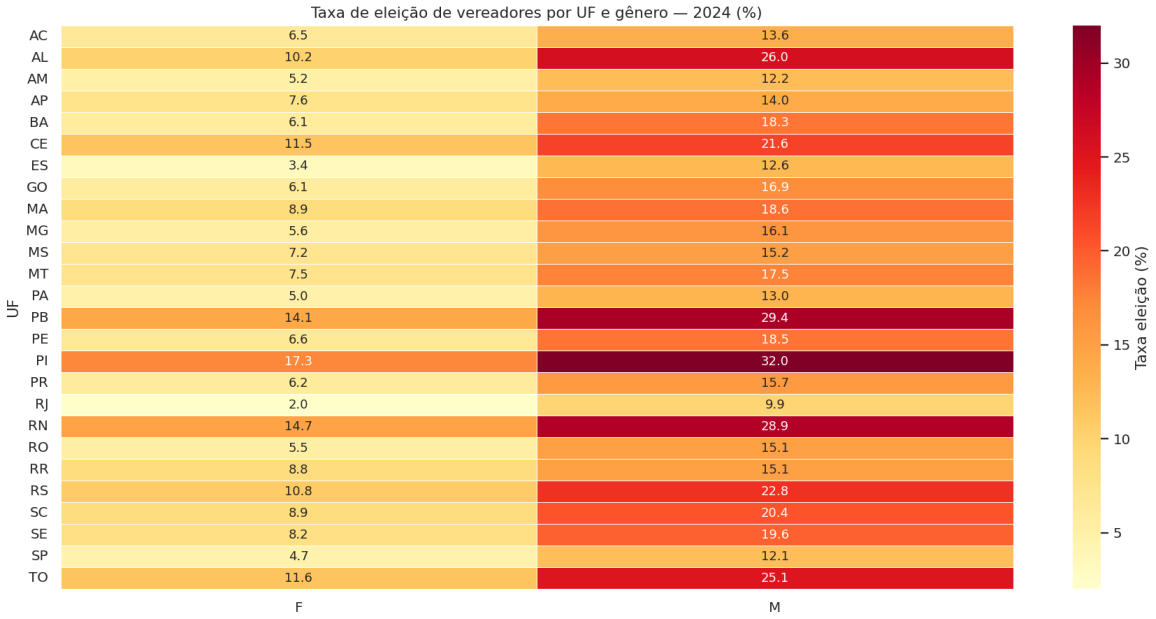

Fig. 5 — Taxa de eleição de vereadores por UF e gênero (2024, %)

6.6 Grau de instrução e taxa de eleição

Candidatos com ensino superior completo e pós-graduação apresentam as maiores taxas de eleição relativas ao seu grupo. Contudo, candidatos analfabetos também apresentam taxa não nula, evidenciando que liderança local e reconhecimento comunitário podem superar barreiras educacionais em municípios menores.

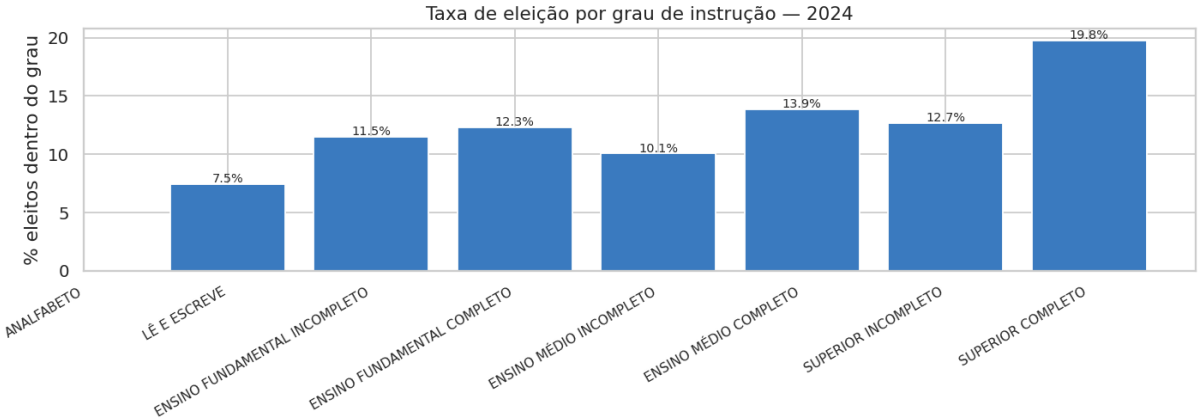

Fig. 6 — Taxa de eleição por grau de instrução (2024)

7. Próximas Etapas

#	Etapa	Descrição	Status
1	Ingestão	Download e extração dos dados TSE 2004–2024	Validado (2024)
2	Pré-processamento	Limpeza, normalização e join dos datasets	Validado (2024)
3	EDA	Análise exploratória multidimensional	Em andamento
4	Escala (todos anos)	Executar pipeline para 2004–2020	Pendente
5	Integração IBGE	Enriquecimento com dados de população e IDHM	Pendente
6	Processamento Paralelo	Refatorar pipeline com PySpark ou Dask	Pendente
7	Detecção de Anomalias	Isolation Forest, LOF, DBSCAN	Pendente
8	Interpretação	Análise dos padrões atípicos identificados	Pendente
9	Relatório Final	Artigo e apresentação para o PPCA	Pendente

Relatório gerado automaticamente pelo pipeline do projeto — PPCA / UnB — Abril 2026